

목차

1장 숫자가 오기까지	2
1.1 같은 것을 세는 두 가지 방법	2
1.2 무엇을 세는지 정하는 일	4
1.3 어떻게 모았는가	6
1.4 숫자가 만들어지는 단계	8
1.5 숫자를 받으면 먼저 묻는 것	9
2장 함께 움직인다는 것	10
2.1 두 값을 나란히 놓기	10
2.2 상관의 세기와 방향	12
2.3 네 가지 흩어짐	14
2.4 평균만 보면 놓치는 것	15
2.5 상관은 대칭이다	17
3장 원인이라고 말하려면	19
3.1 세 번째 값이 숨어 있을 때	19
3.2 화살표의 방향	21
3.3 상관이 인과가 아닌 세 갈래	23
3.4 비교할 집단을 만드는 일	24
4장 누가 표본에 들어왔는가	26
4.1 답한 사람만 세면	26
4.2 살아남은 것만 보면	28
4.3 빠진 자리	30
4.4 스스로 고른 사람들	31
5장 실제로 읽어 보기	34
5.1 배달 건수와 사고 건수	34
5.2 야간 조명과 매출	36
5.3 같은 자료 두 가지 해석	38
5.4 자연실험을 찾아내기	39
6장 다루는 사람이 만드는 왜곡	42
6.1 시점을 고르면 그림이 바뀐다	42
6.2 기저효과	44
6.3 같은 자료 다른 구간	46
6.4 지표가 목표가 되면	47
7장 결론: 자료는 세상을 본 기록이다	49
7.1 다섯 가지 물음	49
7.2 자료는 세상을 본 기록이다	51
7.3 다시 조사실로	53

1.1 같은 것을 세는 두 가지 방법

새들목은 시장 골목과 뒷길 카페가 뒤섞인 작은 상권이다. 상인회는 해마다 이 골목에 사람이 얼마나 오는지를 세어 회보에 싣는다. 어느 해에 그 숫자가 두 개로 같았다.

조사원 예린이 낸 숫자와 상인회장 만수가 들고 온 숫자가 두 배 가까이 차이 났다. 두 사람 다 성실하게 셧고 어느 쪽도 부풀리지 않았다. 갈린 이유는 세는 방법에 있었다. 예린은 골목 입구 두 곳에 서서 들어오는 사람을 셧고, 만수는 가게들이 적어 낸 손님 수를 더했다. 골목에 들어와 세 가게를 들른 사람은 예린의 셈에서 한 번, 만수의 셈에서 세 번 세어졌다.

어느 쪽이 맞느냐고 물으면 답하기 어렵다. 알고 싶은 것이 골목에 온 사람 수라면 예린 쪽이고, 가게가 치른 응대 횟수라면 만수 쪽이다. 두 숫자는 다른 것을 셧고 있었고, 그러면서도 같은 이름으로 회보에 실릴 뻔했다. 이 책은 이런 자리에서 시작한다. 숫자를 읽기 전에 그 숫자가 어떻게 만들어졌는지를 먼저 보는 습관에 관한 이야기다. 도구를 배우기 전에 재료를 살피는 일이 먼저라는 뜻이기도 하다.

1.1 같은 것을 세는 두 가지 방법

문제는 두 숫자가 나란히 놓일 때 커진다. 갈린 것을 알아차리지 못하면 없는 변화를 본 것으로 착각하게 된다.

새들목 회보에는 실제로 그런 일이 있었다. 세 해 동안은 만수의 방식으로, 그다음 두 해는 예린의 방식으로 센 숫자가 한 줄에 이어 붙어 있었다. 표만 보면 네 번째 해에 방문객이 갑자기 반토막이 난 것처럼 보였다. 그해 회의에서는 상권이 죽어 간다는 말이 오갔고, 골목 입구에 현수막을 다는 예산이 편성됐다.

실제로 줄어든 것은 방문객이 아니라 세는 방식이 바뀌면서 생긴 겉세기였다. 방식이 바뀐 해를 표에 적어 두었더라면 아무도 그 줄을 이어 붙이지 않았을 것이다. 숫자를 견주는 일은 같은 자로 잰 것인지 확인하는 데서 시작한다. 이 확인을 건너뛰면 그다음의 정교한 분석은 모두 헛돈다. 회보의 그 줄은 이듬해에 두 토막으로 나뉘어 다시 실렸다. 방식이 바뀐 해를 사이에 두고 앞뒤를 따로 그린 것이다. 보기에는 덜 깔끔했지만 적어도 없는 변화를 만들어 내지는 않았다. 끊긴 자리를 보이게 두는 편이 이어 붙여 감추는 것보다 낫다.

1.2 무엇을 세는지 정하는 일

겹세기를 겪은 뒤 새들목 조사실이 가장 먼저 한 일은 세려는 것의 경계를 글로 적는 일이었다. 이렇게 적어 둔 경계를 자료 정의라고 부른다.

적어 보니 정할 것이 생각보다 많았다. 골목에 들어왔다가 아무 데도 들르지 않고 지나간 사람은 방문객인가. 같은 사람이 오전과 저녁에 두 번 오면 한 명인가 두 명인가. 배달을 받으러 잠깐 들어온 사람은 어떤가. 골목 안에 사는 사람은 세는가. 각각의 답에 옳고 그름이 있는 것은 아니지만, 정해 두지 않으면 세는 사람마다 다르게 처리한다.

정의를 적는 일의 쓸모는 그 순간보다 나중에 드러난다. 세 해 뒤에 다른 사람이 같은 조사를 이어받을 때, 정의가 적혀 있으면 같은 방식으로 셀 수 있다. 적혀 있지 않으면 그 사람은 자기 나름의 기준으로 세게 되고, 앞에서 본 것처럼 두 시기의 숫자가 조용히 갈린다. 자료 정의는 조사의 첫 문장이자 그 자료를 쓰는 모든 사람이 공유해야 하는 약속이다. 정의가 없는 자료는 쓰는 사람마다 다른 것을 세고 있다고 보아야 한다.

1.2 무엇을 세는지 정하는 일

정의는 한 번 정하면 영원히 두는 것이 아니다. 사정이 바뀌면 고쳐야 한다. 새들목에도 배달 주문이 늘면서 방문객이라는 정의만으로는 상권의 사정을 담기 어려워진 때가 왔다.

고칠 때 지켜야 하는 절차가 있다. 첫째, 바꾼 해를 기록에 표시한다. 둘째, 가능하면 한 해쯤은 옛 방식과 새 방식으로 함께 세어 둔다. 두 방식으로 낸 숫자가 한 해라도 겹쳐 있으면 그 차이만큼을 알 수 있고, 앞뒤 시기를 이어 붙일 때 그 차이를 보정할 수 있다.

겹쳐 재는 한 해는 품이 두 배로 들지만 그만한 값을 한다. 겹치는 구간이 없으면 정의가 바뀐 시점에서 자료가 끊기고, 그 앞뒤를 건주는 모든 분석이 불가능해진다. 새들목은 배달 건수를 새로 세기 시작한 해에 이 겹쳐 재기를 했고, 덕분에 지금도 열 해치 흐름을 한 줄로 볼 수 있다. 겹쳐 재지 않고 정의만 바꾼 항목도 하나 있었는데, 그 항목은 지금도 바뀐 해 앞뒤를 건줄 수 없다. 같은 조사실 안에 두 방식의 결과가 나란히 남아 있는 셈이다.

1.3 어떻게 모았는가

정의를 정했다고 끝이 아니다. 그 정의대로 실제로 어떻게 썼는지가 숫자에 그대로 남는다.

예린이 골목 입구에서 썼던 첫해를 보자. 예린은 평일 낮과 토요일 오후에만 나갔다. 그 시간대의 방문객은 정확히 썼지만 새벽 배송을 받으러 오는 사람이나 늦은 밤 술집 손님은 아예 세어지지 않았다. 자료에 그 사람들은 존재하지 않는 셈이 됐다. 자리를 골목 입구 두 곳으로 잡은 것도 마찬가지다. 뒷길로 들어오는 사람은 빠졌다.

그래서 어떤 자료든 그것은 세상 자체가 아니라 어떤 절차로 세상을 본 기록이다. 시간대, 위치, 세는 사람, 쓰는 도구가 모두 그 기록에 흔적을 남긴다. 자료를 받았을 때 숫자보다 먼저 볼 것은 이 절차이고, 절차를 알 수 없는 자료는 정확도를 따질 수도 없다. 4장에서 다룰 표본편향은 결국 이 절차가 특정한 사람들만 걸러 낸 결과다. 그러니 자료의 정확도를 말할 때 숫자가 얼마나 정밀한지만 따지는 것은 절반이다. 정밀하게 잴 것이 애초에 한쪽만 담고 있으면 정밀함은 도움이 되지 않는다.

1.3 어떻게 모았는가


절차를 남긴다는 것이 거창한 문서를 뜻하지는 않는다. 새들목 조사실이 쓰는 양식은 반 장짜리다.

거기에는 다섯 가지가 적힌다. 언제 잤는지(날짜와 시간대), 어디서 잤는지(지점), 누가 잤는지, 어떤 도구로 잤는지, 그리고 빠뜨린 것이 있으면 무엇을 빠뜨렸는지다. 마지막 항목이 특히 중요하다. 비가 와서 한 지점을 건너뛴 날, 계수기가 고장 나 손으로 센 날은 그대로 적어 둔다.

이 반 장이 없으면 몇 해 뒤에 그 자료를 다시 볼 수 없다. 어느 해의 숫자가 유난히 튀어 보일 때, 그것이 실제 변화인지 그날 계수기가 고장 났던 탓인지 알 방법이 사라지기 때문이다. 자료를 남기는 일과 자료를 만든 방식을 남기는 일은 한 쌍이고, 뒤쪽을 빠뜨린 자료는 시간이 지날수록 해석할 수 없는 숫자 더미가 된다. 새들목 조사실의 서랍에는 십 년 전 자료가 한 상자 있는데, 절차 기록이 없어 지금은 아무도 쓰지 않는다. 숫자만 남은 자료는 버릴 수도 쓸 수도 없는 상태로 자리만 차지한다. 절차 반 장이 자료 한 상자의 수명을 정한 셈이다.

숫자가 만들어지는 단계

세상에서 표까지 오는 동안 무엇이 빠지는가



마지막 상자에 담긴 숫자만 보고는 앞의 네 단계를 알 수 없다

자료는 세상 자체가 아니라 이 단계를 거친 기록이다.
단계마다 무엇이 빠졌는지 적어 두어야 나중에 읽을 수 있다.

1.5 숫자를 받으면 먼저 묻는 것

낯선 표를 받았을 때 새들목 조사실 사람들이 먼저 던지는 물음은 셋이다.

무엇을 센 숫자인가. 정의가 적혀 있는지, 적혀 있지 않다면 물어볼 수 있는지 확인한다. 어떻게 센 숫자인가. 언제 어디서 누가 어떤 방식으로 모았는지를 본다. 그리고 무엇이 빠졌는가. 세지 못한 대상, 답하지 않은 사람, 기록이 끊긴 기간이 있는지 확인한다.

셋 중 하나라도 답을 못 얻으면 그 자료로 할 수 있는 말의 범위를 줄인다. 없는 자료를 억지로 쓰는 것보다 여기까지만 말할 수 있다고 적는 편이 낫기 때문이다. 이 세 물음은 뒤에 나올 상관이나 인과 같은 도구를 쓰기 전 단계에 있다. 아무리 좋은 도구도 잘못 만들어진 숫자에 대고 쓰면 잘못된 결론을 정교하게 만들어 줄 뿐이다. 세 물음에 답하는 데 오래 걸리지도 않는다. 정의와 절차가 적혀 있으면 몇 분이면 끝나고, 적혀 있지 않으면 그 사실을 아는 데 몇 분이면 된다. 어느 쪽이든 표를 읽기 시작하기 전에 하는 편이 낫다. 읽고 나서 확인하면 이미 머릿속에 그림이 생긴 뒤라 되돌리기 어렵다.

2.1 두 값을 나란히 놓기

새들목 조사실에는 여러 줄의 숫자가 쌓여 있다. 날짜별 방문객 수, 날씨, 가게별 매출, 배달 건수, 골목 조명을 켜 시간 같은 것들이다.

두 줄을 골라 나란히 놓으면 이런 물음을 던질 수 있다. 한쪽이 큰 날에 다른 쪽도 큰가. 방문객이 많은 날에 매출도 많은가. 비가 온 날에 배달 건수가 늘었는가. 이렇게 두 값이 함께 움직이는 정도를 상관이라고 부른다.

상관을 보는 가장 단순한 방법은 짝지어 찍어 보는 것이다. 가로축에 한 값, 세로축에 다른 값을 두고 날마다 점을 하나씩 찍는다. 점들이 오른쪽 위로 몰려 있으면 한쪽이 클 때 다른 쪽도 크다는 뜻이고, 오른쪽 아래로 몰려 있으면 한쪽이 클 때 다른 쪽이 작다는 뜻이다. 아무 모양도 없이 흩어져 있으면 두 값은 별 관계가 없다. 숫자를 계산하기 전에 이 그림부터 그려 보는 것이 조사실의 오랜 습관이다. 계산된 값 하나는 여러 모양을 같은 숫자로 뭉뚱그리지만 그림은 그 모양을 그대로 보여 준다. 어느 쪽이 먼저인지는 뒤에서 따로 다룬다.

2.1 두 값을 나란히 놓기

두 줄을 나란히 놓는 일이 늘 간단하지는 않다. 붙이기 전에 맞춰야 하는 것이 몇 가지 있다.

첫째는 기간이다. 한쪽은 날마다 적혀 있고 다른 쪽은 달마다 적혀 있으면 그대로 짝지을 수 없다. 날짜별 자료를 달 단위로 합치든지 해야 하는데, 합치는 순간 하루 안의 움직임은 사라진다. 둘째는 단위다. 한쪽은 건수이고 다른 쪽은 금액이면 크기를 그대로 견줄 수 없고, 그림의 축을 각각 따로 잡아야 한다.

셋째가 가장 자주 걸린다. 1장에서 본 정의 문제다. 두 줄이 서로 다른 시기에 다른 방식으로 만들어졌다면, 그림에 나타나는 모양은 두 값의 관계가 아니라 방식이 바뀐 흔적일 수 있다. 새들목에서 방문객과 매출을 처음 짝지어 봤을 때 이상한 꺾임이 나왔는데, 원인은 방문객 세는 방식이 바뀐 해였다. 세 가지를 맞추고 나면 그림을 그리는 일 자체는 금방이다. 맞추는 데 드는 시간이 대부분이고, 그 시간을 아끼려다 잘못된 그림을 오래 들여다보게 되는 일이 흔하다. 맞추는 일은 지루하지만 건너뛸 수 있는 단계가 아니다.

2.2 상관의 세기와 방향

그림을 그리고 나면 두 가지를 말할 수 있다. 방향과 세기다.

방향은 함께 커지는지 반대로 가는지다. 방문객이 많은 날에 매출도 많으면 같은 방향이고, 비가 많이 온 날에 방문객이 적으면 반대 방향이다. 세기는 그 경향이 얼마나 뚜렷한지다. 점들이 좁은 띠 안에 촘촘히 모여 거의 선을 이루면 강한 상관이고, 넓게 퍼져 있어 경향이 겨우 보일 정도면 약한 상관이다.

여기서 조심할 것이 있다. 강하다는 말은 관계가 확실하다는 뜻이지 크다는 뜻이 아니다. 방문객이 한 명 늘 때 매출이 아주 조금 늘더라도, 그 조금이 언제나 규칙적으로 늘어난다면 상관은 강하다. 반대로 방문객이 한 명 늘 때 매출이 크게 늘지만 날마다 들쭉날쭉하면 상관은 약하다. 얼마나 함께 움직이는가와 얼마나 크게 움직이는가는 다른 물음이고, 둘을 섞으면 그림을 잘못 읽게 된다. 실무에서는 두 물음이 다 필요하다. 관계가 확실한지는 판단을 얼마나 믿을지에 관한 것이고, 얼마나 크게 움직이는지는 그 판단이 실제로 쓸모가 있는지에 관한 것이다.

2.2 상관의 세기와 방향

점이 다섯 개뿐인 그림에서도 선처럼 보이는 모양은 쉽게 나온다. 그래서 그림을 읽기 전에 점이 몇 개인지부터 봐야 한다.


새들목에서 겪은 일이 있다. 새 메뉴를 낸 카페 다섯 곳의 매출을 조명 시간과 짝지어 봤더니 아주 뚜렷한 모양이 나왔다. 조명을 오래 켜 가게일수록 매출이 높았다. 그런데 다음 달에 열두 곳으로 늘려 다시 그리자 그 모양은 거의 사라졌다. 처음 다섯 곳에서 보인 선은 우연히 그렇게 배치된 것이었다.

점이 적을수록 우연한 모양이 나올 여지가 크다. 특히 극단적인 점 하나가 전체 모양을 끌고 가는 일이 흔하다. 그래서 그림을 볼 때는 점 하나를 가려 보고 모양이 크게 달라지는지 확인한다. 하나를 빼자 경향이 사라진다면 그것은 두 값의 관계라기보다 그 한 점의 이야기다. 그 점을 버리라는 뜻은 아니다. 오히려 왜 그 점만 유난한지 따로 알아볼 값어치가 있다. 다만 그 점을 포함한 채로 전체 경향을 말하는 것은 다른 문제이고, 그럴 때는 점을 뺐을 때와 넣었을 때를 함께 적는다.

네 가지 흠어짐


방향과 세기가 비슷해 보여도 모양은 다르다

곧은 관계



값이 커질수록 고르게 커진다

휨 관계



어느 지점부터 꺾인다

한 점이 끄는 경우



그 점을 빼면 경향이 사라진다

두 무리가 섞인 경우



나누면 각 무리 안에는 경향이 없다

요약된 숫자 하나로는 네 그림을 구분하지 못한다.
계산하기 전에 그려 보는 이유가 여기 있다.

2.4 평균만 보면 놓치는 것

자료를 다루다 보면 표 하나를 몇 개의 숫자로 줄이게 된다. 평균이 가장 흔하다. 줄이는 일은 필요하지만 무엇이 사라지는지 알고 줄여야 한다.

새들목의 두 골목이 좋은 예다. 시장 골목과 뒷길의 가게당 평균 매출은 거의 같았다. 그런데 안을 들여다보니 전혀 달랐다. 시장 골목은 대부분의 가게가 평균 근처에 몰려 있었고, 뒷길은 아주 잘되는 가게 두 곳과 그렇지 않은 여러 곳으로 갈려 있었다. 평균이 같다는 사실만 놓고 두 골목이 비슷하다고 말하면 뒷길의 사정을 통째로 놓친다.

그래서 평균을 볼 때는 흩어진 정도를 함께 본다. 값들이 평균 가까이 모여 있는지 넓게 퍼져 있는지, 유난히 큰 값 몇 개가 평균을 끌어올리고 있지는 않은지 확인한다. 가능하면 요약하기 전에 값들을 그대로 늘어놓은 그림을 한 번 보는 편이 낫다. 그림을 보고 나면 어떤 요약이 그 자료에 맞는지도 함께 정할 수 있다. 요약을 먼저 정하고 그림을 나중에 보면 이미 고른 요약에 맞는 것만 눈에 들어온다. 순서를 지키는 것만으로도 걸러지는 실수가 있다.

2.4 평균만 보면 놓치는 것

합쳐서 보는 일에는 더 고약한 함정이 있다. 무리를 나누어 보면 방향이 반대로 나오는 경우다.

새들목에서 가게 스무 곳의 조명 시간과 매출을 한꺼번에 그렸을 때는 오래 켤수록 매출이 높다는 모양이 나왔다. 그런데 시장 골목과 뒷길을 나누어 그리자 두 골목 모두에서 그 관계가 사라지거나 오히려 반대가 됐다. 무슨 일이 있었을까.

시장 골목 가게들은 원래 매출이 높고 문도 늦게까지 연다. 뒷길 가게들은 매출이 낮고 일찍 닫는다. 두 골목을 합쳐 놓으면 골목 차이가 조명 시간과 매출 양쪽에 함께 나타나면서, 마치 조명이 매출을 끌어올린 것처럼 보이는 모양이 만들어진다. 합친 그림에 나타난 것은 조명과 매출의 관계가 아니라 두 골목의 차이였다. 이 구조가 다음 장의 주제다. 이런 일은 무리가 섞여 있을 때 언제든지 생길 수 있고 미리 알아차리기는 어렵다. 그래서 나눌 수 있는 무리가 있으면 일단 나누어 한 번 더 그려 보는 것이 안전하다. 나누어도 같은 모양이면 그때 합쳐서 이야기하면 된다.

2.5 상관은 대칭이다

상관에는 한 가지 성질이 있다. 두 값을 어느 쪽 축에 놓아도 그림의 모양은 같다는 것이다.

방문객을 가로축에 두고 매출을 세로축에 두든, 반대로 두든 점들의 배치는 그대로다. 함께 움직인다는 사실만 있고 누가 먼저인지는 그 안에 없다. 그래서 상관을 계산한 뒤에 방문객이 매출을 늘렸다고 말하는 것과 매출이 방문객을 늘렸다고 말하는 것은, 상관만 놓고 보면 똑같이 근거가 없다.

이 대칭성이 이 책에서 가장 자주 되돌아오는 사실이다. 자료에서 함께 움직인다는 것까지는 읽어 낼 수 있지만, 어느 쪽이 어느 쪽을 움직였는지는 자료 밖의 무언가를 더해야 말할 수 있다. 그 무언가가 무엇인지, 그리고 어떻게 더하는지가 3장의 내용이다. 이 사실은 답답하게 들리지만 실은 보호막이기도 하다. 상관만으로 방향을 말할 수 없다는 것을 알고 있으면, 남이 그렇게 말할 때 무엇을 더 물어야 하는지도 알게 되기 때문이다. 새들목 회의에서 오간 논쟁 대부분이 이 물음 하나로 정리됐다. 어느 쪽이 먼저냐고 되물으면 대개 답이 없었기 때문이다.

2.5 상관은 대칭이다

상관에 방향이 없다는 것을 알면서도, 우리는 그림을 보면 거의 자동으로 방향을 읽는다.

조명 시간과 매출의 그림을 본 사람들은 대부분 조명이 매출을 올렸다고 읽었다. 매출이 좋은 가게가 조명을 오래 켜다는 반대 방향은 잘 떠올리지 않는다. 왜 그럴까. 우리가 이미 머릿속에 어떤 이야기를 갖고 있기 때문이다. 조명이 손님을 부른다는 이야기는 익숙하고, 매출이 조명을 늘린다는 이야기는 덜 익숙하다.

익숙한 이야기가 그림에 얹히는 것 자체는 나쁘지 않다. 문제는 그 이야기가 자료에서 나온 것처럼 착각하는 데 있다. 자료가 보여 준 것은 함께 움직인다는 사실 하나뿐이고, 방향은 우리가 얹은 것이다. 이 구분을 분명히 해 두면 다음 장에서 무엇을 더 확인해야 하는지가 자연스럽게 나온다. 익숙한 이야기가 늘 틀린 것도 아니다. 조명이 손님을 부른다는 이야기는 그럴듯하고 실제로 맞을 수도 있다. 요점은 그 이야기가 아직 확인되지 않았다는 것을 잊지 않는 것이고, 확인하는 방법이 다음 장에 있다.

3.1 세 번째 값이 숨어 있을 때

앞 장 끝에서 본 조명과 매출의 사례로 돌아가 보자. 두 값이 함께 움직인 이유는 셋째 값 때문이었다. 어느 골목에 있는 가게인가 하는 것이다.

시장 골목이라는 조건은 두 가지에 동시에 영향을 준다. 그 골목의 가게는 원래 손님이 많아 매출이 높고, 손님이 늦게까지 있으니 조명도 오래 켜다. 조명과 매출 사이에는 아무 힘이 오가지 않았는데도, 골목이라는 셋째 값이 둘을 함께 끌어올려 그림에 선을 만들어 놓은 것이다.

이렇게 두 값 모두에 영향을 주어 없는 관계를 있는 것처럼 보이게 만드는 값을 교란변수라고 부른다. 교란변수가 있으면 상관이 아무리 강해도 인과의 근거가 되지 못한다. 그리고 고약하게도 교란변수는 대개 자료에 적혀 있지 않다. 조명과 매출만 적힌 표를 아무리 들여다봐도 골목이라는 값은 나오지 않는다. 자료 밖의 지식이 필요하다고 한 것이 이 뜻이다. 교란변수라는 이름이 붙은 것도 그것이 두 값 사이의 관계를 어지럽히기 때문이다. 어지럽힌다는 말에는 없는 관계를 만든다는 뜻과 있는 관계를 가린다는 뜻이 함께 들어 있다.

3.1 세 번째 값이 숨어 있을 때

교란변수는 자료에 없으므로 찾아내려면 자료 밖을 봐야 한다. 새들목에서 쓰는 방법은 둘이다.

첫째는 나누어 보는 것이다. 짐작 가는 조건이 있으면 그 조건으로 무리를 나누어 각각 그림을 그린다. 골목별로 나누자 조명과 매출의 관계가 사라진 것이 그 예다. 무리를 나누어도 관계가 그대로 남아 있으면 그 조건은 교란변수가 아니다. 이 방법의 한계는 짐작한 조건만 확인할 수 있다는 것이다.

둘째는 후보를 미리 적어 보는 것이다. 두 값 모두에 영향을 줄 만한 것이 무엇인지 아는 사람들에게 물어 목록을 만든다. 새들목에서는 상인들에게 물었고, 골목 위치 말고도 가게 규모, 문 여는 시간, 주인의 나이 같은 후보가 나왔다. 목록을 만들어 두면 그중 자료에 있는 것부터 하나씩 나누어 볼 수 있고, 자료에 없는 것은 앞으로 모을 항목이 된다. 두 방법 모두 완전하지 않다. 짐작하지 못한 값은 어느 쪽으로도 걸러지지 않기 때문이다. 그래서 교란변수를 다 없앴다고 말하는 대신, 확인한 후보와 확인하지 못한 후보를 함께 적는 것이 정직한 보고가 된다.

3.2 화살표의 방향

교란변수가 없다고 해도 아직 인과라고 말할 수 없다. 방향이 반대일 수 있기 때문이다.

새들목의 다른 사례를 보자. 손님이 많은 가게일수록 직원 수가 많았다. 이 그림을 보고 직원을 늘리면 손님이 늘다고 읽은 사람이 있었다. 실제로는 손님이 많아진 가게가 감당하기 위해 직원을 늘린 것이었다. 카페 주인 다울은 손님이 줄어든 달에 직원을 하나 내보냈는데, 그림상으로는 직원이 줄어서 손님이 줄어든 것처럼 보였다.

이렇게 원인과 결과가 뒤바뀌어 읽히는 것을 역인과라고 부른다. 자료만 보면 두 방향이 똑같아 보이므로, 가려내려면 시간 순서나 그 일이 벌어진 사정을 알아야 한다. 어느 쪽이 먼저 움직였는지 날짜로 확인할 수 있으면 다행이지만, 두 값이 서로를 밀고 당기는 경우도 많아 그때는 방향을 하나로 정하는 것 자체가 잘못된 물음이 된다. 서로 밀고 당기는 관계에서 물어야 할 것은 방향이 아니라 크기다. 어느 쪽 힘이 더 센지, 한 바퀴 돌 때 얼마나 커지는지를 묻는 편이 답을 얻을 수 있는 물음이다.

3.2 화살표의 방향

방향을 가리는 가장 흔한 방법은 시간 순서를 보는 것이다. 먼저 일어난 쪽이 원인이라는 짐작이다. 쓸모는 있지만 그것만으로는 부족하다.

첫째, 먼저 일어났다고 원인인 것은 아니다. 새벽에 닭이 울고 해가 뜨지만 닭이 해를 뜨게 하지는 않는다. 둘째, 기록된 시간과 실제로 일어난 시간이 다를 수 있다. 다울이 직원을 내보낸 것은 손님이 줄기 시작한 지 두 달 뒤였지만, 줄어들 것을 예상하고 미리 준비한 부분도 있었다. 셋째, 앞으로 벌어질 일을 내다보고 지금 움직이는 경우에는 순서가 뒤집혀 보이기까지 한다.

그래서 시간 순서는 방향을 정하는 근거 중 하나일 뿐 결정적인 증거는 아니다. 순서에 더해 그 일이 어떤 경로로 다른 쪽에 영향을 주는지 설명할 수 있어야 하고, 가능하면 다음 절에서 볼 비교집단이 있어야 한다. 경로를 설명하라는 요구는 생각보다 힘이 세다. 조명이 매출을 올린다면 어떤 경로일까. 지나가던 사람이 밝은 가게를 보고 들어온다는 경로라면, 들어온 손님 수가 실제로 늘었는지 따로 확인할 수 있다. 경로를 적으면 확인할 거리가 하나 더 생긴다.

함께 움직일 때 가능한 네 구조


자료만으로는 넷이 똑같아 보인다

직접



한쪽이 실제로 움직인다

교란



셋째 값이 둘을 함께 움직인다

역인과



화살표가 반대다

우연



아무 화살표도 없다

네 구조 모두 같은 점그림을 만든다.
가르려면 자료 밖의 지식이나 갈림이 필요하다.

3.4 비교할 집단을 만드는 일

어떤 일이 효과가 있었는지 말하려면 그 일을 하지 않았을 때 무슨 일이 일어났을지를 알아야 한다. 그러나 같은 가게가 조명을 켜면서 동시에 켜지 않을 수는 없다.

그래서 대신 쓰는 것이 비교집단이다. 조명을 늘린 가게들과 늘리지 않은 가게들을 나란히 놓고 두 무리의 변화를 견준다. 이때 두 무리가 조명 말고 다른 점에서 되도록 비슷해야 한다. 한쪽은 시장 골목이고 다른 쪽은 뒷길이라면 견줘 봐야 골목 차이만 보게 된다.

비슷하게 만드는 가장 확실한 방법은 누가 어느 무리에 들어갈지를 사람이 정하지 않고 뽑기로 정하는 것이다. 뽑기로 나누면 알려진 차이든 모르는 차이든 두 무리에 고르게 섞이므로, 남은 차이를 조명 탓으로 돌릴 수 있다. 새들목에서 실제로 이렇게 해 본 적이 있는데, 참여를 원하는 가게가 적어 무리가 작았다. 뽑기가 어려울 때 무엇을 할 수 있는지는 5장에서 다룬다. 뽑기가 늘 가능하지는 않다는 점이 자료를 다루는 일의 가장 큰 제약이며, 이 책의 나머지 절반은 사실상 그 제약을 우회하는 방법들이다.

3.4 비교할 집단을 만드는 일

뽑기로 나누지 못하면 대개 스스로 하겠다고 나선 쪽과 나서지 않은 쪽을 견주게 된다. 이 방식에는 큰 구멍이 있다.

새들목의 조명 실험이 그랬다. 하겠다고 나선 가게들은 대부분 원래 의욕이 있고 새로운 것을 잘 시도하는 주인들이었다. 몇 달 뒤 이 가게들의 매출이 나서지 않은 가게들보다 높았지만, 그 차이가 조명 때문인지 원래 그런 주인들이어서인지 알 방법이 없었다.

이 구멍은 자료를 아무리 정교하게 다뤄도 메워지지 않는다. 나선 사람과 나서지 않은 사람의 차이가 무엇인지 전부 알 수 없기 때문이다. 그래서 스스로 고른 무리를 견준 결과는 언제나 조건을 붙여 읽어야 한다. 이런 성격의 편향을 4장에서 자기선택이라는 이름으로 다시 다룬다. 그렇다고 스스로 고른 무리를 견주는 일이 전혀 쓸모없지는 않다. 결과가 아무 차이도 없게 나왔다면 의욕 있는 주인들이 모인 무리에서도 효과가 없었다는 뜻이므로 오히려 강한 근거가 된다. 어느 방향의 결론이냐에 따라 같은 자료의 무게가 달라진다. 효과가 있다는 결론일 때만 특히 조심하면 된다.

4.1 답한 사람만 세면

새들목 조사실은 해마다 상인들에게 설문을 돌린다. 어느 해 회수율이 사십 분의 일도 되지 않았는데, 그 결과에는 상권 만족도가 꽤 높게 나왔다.

예린이 답하지 않은 가게들을 찾아가 물었더니 사정이 보였다. 답하지 않은 가게 중에는 장사가 어려워 문 닫을 준비를 하는 곳, 주인이 혼자 일해 설문을 채울 시간이 없는 곳이 많았다. 답을 보낸 쪽은 상대적으로 여유가 있고 상권 일에 관심이 있는 가게들이었다.

답하지 않은 사람들이 빠지면서 결과가 한쪽으로 치우치는 것을 무응답편향이라고 부른다. 여기서 중요한 것은 이것이 단순히 자료가 적은 문제가 아니라는 점이다. 적으면 숫자가 흔들릴 뿐이지만, 치우치면 아무리 많이 모아도 같은 방향으로 틀린다. 회수율을 두 배로 올려도 답하는 성향이 같다면 결과는 여전히 높게 나온다. 이 점이 표본 문제에서 가장 자주 오해되는 자리다. 자료를 더 모으면 나아진다는 생각은 무작위로 빠졌을 때만 맞는다. 빠지는 방식에 방향이 있으면 더 모을수록 틀린 값에 더 확신을 갖게 된다. 양이 늘어난 만큼 틀린 값의 폭만 좁아진다.

4.1 답한 사람만 세면

빠진 사람들을 다 데려올 수 없다면, 적어도 그들이 어느 방향으로 다를지는 짐작해 봐야 한다. 두 가지 방법이 있다.

첫째는 응답률을 무리별로 쪼개 보는 것이다. 시장 골목 가게는 절반이 답했는데 뒷길은 열에 하나만 답했다면, 결과가 시장 골목 쪽으로 기울어 있다는 것을 알 수 있다. 무리별 응답률만 알아도 어느 쪽이 과대 대표됐는지 짚을 수 있다.

둘째는 답하지 않은 쪽에서 몇 곳을 골라 직접 찾아가는 것이다. 전부는 못 하더라도 스무 곳쯤 만나 같은 질문을 하면, 답한 쪽과 얼마나 다른지 어림할 수 있다. 새들목이 실제로 한 일이 이것이고, 그 결과 만족도가 회보에 실린 숫자보다 상당히 낮다는 것을 알게 됐다. 그해 회보에는 숫자와 함께 이 어림도 나란히 실렸다. 나란히 실는 방식에는 반대도 있었다. 두 숫자가 있으면 어느 것을 믿어야 하느냐는 것이었다. 예린의 답은 단순했다. 하나만 실으면 그 하나를 믿게 되는데, 그 하나가 치우쳐 있다는 것을 이미 알고 있다는 것이었다. 두 숫자를 나란히 두면 적어도 폭은 보인다.

4.2 살아남은 것만 보면

새들목 회보에 골목 가게들의 평균 영업 기간이 실린 적이 있다. 예상보다 길게 나와서, 이 골목은 한번 자리 잡으면 오래간다는 문장이 붙었다.

그 숫자는 그해 영업 중인 가게들만 세어 만든 것이었다. 일찍 문을 닫은 가게들은 목록에 아예 없었다. 두 해를 못 넘기고 사라진 가게가 그동안 여럿이었는데, 그들은 조사 대상 명단에 오르지 못했다. 남아 있는 가게만 세면 오래가는 가게만 세게 되고, 그 결과 이 골목이 안정적이라는 결론이 나온다.

이렇게 사라진 것들이 자료에서 빠지면서 생기는 치우침을 생존편향이라고 부른다. 성공한 가게들의 공통점을 찾는 조사, 오래된 물건이 튼튼하다는 인상, 옛날 방식이 더 나았다는 회고가 모두 이 구조를 안고 있다. 실패해 사라진 쪽에도 같은 공통점이 있었는지는 남아 있는 자료만 봐서는 알 수 없다. 생존편향이 특히 다루기 어려운 것은 빠진 쪽이 눈에 띄지 않기 때문이다. 무응답은 회수율이라는 숫자로라도 드러나지만, 사라진 가게는 명단에 흔적조차 남기지 않는다.

4.2 살아남은 것만 보면

생존편향을 막는 방법은 뜻밖에 단순하다. 지금 남아 있는 것을 세는 대신, 어느 시점의 명단을 고정해 두고 그 뒤를 따라가는 것이다.


새들목이 바꾼 방식이 그랬다. 어느 해 삼월의 가게 명단을 통째로 적어 두고, 해마다 그 명단의 가게들이 어떻게 됐는지를 기록했다. 문을 닫은 가게는 닫았다고 적히고 목록에서 사라지지 않는다. 이렇게 하면 몇 해 뒤에 이 명단으로 평균 영업 기간을 셀 때 사라진 가게가 셈에 들어간다.

이 방식의 값은 미리 시작해야 한다는 것이다. 지금 남아 있는 가게에게 언제 시작했는지 물어보는 것으로는 대신할 수 없다. 이미 사라진 가게에게는 물어볼 수 없기 때문이다. 그래서 생존편향은 자료를 분석하는 단계가 아니라 모으는 단계에서 막아야 하고, 모으는 방식을 정할 때 무엇이 빠질지 미리 생각해 두어야 한다. 새들목이 명단을 고정한 뒤 처음 셈한 평균 영업 기간은 이전 발표의 절반을 조금 넘는 수준이었다. 골목이 안정적이라는 문장은 회보에서 조용히 사라졌다. 셈을 바꾸자 결론도 함께 바뀐 것이다.

빠진 자리


빠지는 방식에 방향이 있는가

고르게 빠진 경우



더 모으면 나아진다

한쪽으로 몰려 빠진 경우



더 모아도 같은 방향으로 틀린다

두 격자에서 자료에 들어온 칸의 수는 같다

빠진 양보다 빠진 방식이 결과를 정한다.

누가 빠졌는지 모르면 얼마나 모았는지도 소용이 없다.

4.4 스스로 고른 사람들

3장 끝에서 본 조명 실험의 문제를 이름 붙일 차례다. 참여 여부를 본인이 정하면 두 무리는 참여라는 조건 말고도 여러 면에서 갈린다. 이것을 자기선택이라고 부른다.

갈리는 방향은 대개 짐작할 수 있다. 새로운 시도에 나서는 쪽은 여유가 있거나 의욕이 있거나 이미 잘되고 있는 경우가 많다. 그러니 나선 무리의 성적이 좋게 나오는 것은 자연스럽고, 그 성적을 그 시도의 효과로 읽으면 과대평가가 된다.

반대 방향도 있다. 어려운 가게일수록 지푸라기라도 잡는 심정으로 나서는 경우다. 이때는 나선 무리의 성적이 나쁘게 나오고, 시도의 효과가 과소평가된다. 어느 방향이든 요점은 같다. 누가 무리에 들어왔는지가 결과보다 먼저 결정돼 있고, 그 결정이 결과와 얽혀 있다는 것이다. 이 얽힘은 참여를 원하는 방식에 따라 달라지기도 한다. 상인회장이 직접 찾아가 권한 가게와 게시판을 보고 스스로 신청한 가게는 다른 무리가 된다. 그래서 참여를 어떻게 모았는지도 절차 기록에 함께 적어 둔다. 권한 방식이 곧 표본을 정하는 방식이기 때문이다.

4.4 스스로 고른 사람들

자기선택을 없앨 수 없을 때 차선은 그것을 자료로 남기는 것이다.

새들목이 두 번째 실험에서 한 일이 그렇다. 참여를 권할 때 모든 가게에 같은 방식으로 알리고, 참여하겠다고 한 곳과 하지 않겠다고 한 곳을 모두 기록했다. 참여하지 않겠다는 가게에는 이유를 한 줄 물었다. 시간이 없다, 효과를 믿지 않는다, 이미 비슷한 것을 하고 있다 같은 답이 모였다.

이 기록이 있으면 나중에 결과를 읽을 때 어느 쪽으로 얼마나 기울었는지 짚을 수 있다. 이미 비슷한 것을 하고 있어 참여하지 않은 가게가 많았다면, 참여한 무리의 성적이 좋아 보이는 것이 당연해진다. 편향을 없애지는 못해도 그 방향과 크기를 짐작하는 데 필요한 재료를 남기는 것이며, 이것이 실무에서 할 수 있는 대부분이다. 이유를 묻는 일에는 다른 쓸모도 있었다. 효과를 믿지 않아 참여하지 않은 가게가 예상보다 많았고, 이전에 비슷한 사업이 흐지부지된 기억 때문이라고 했다. 자료를 모으려던 물음이 상권의 다른 사정을 알려 준 셈이다.

4.4 스스로 고른 사람들

4장에서 다룬 세 가지는 이름이 다르지만 뿌리가 같다. 누가 자료에 들어왔는지가 우연히 정해지지 않았다는 것이다.

무응답에서는 답할 여유가 있는 사람이 들어왔고, 생존에서는 살아남은 것이 들어왔고, 자기선택에서는 나서기로 한 사람이 들어왔다. 셋 다 들어오고 빠지는 일이 결과와 얽혀 있어서, 자료 안에서 아무리 정교하게 계산해도 그 얽힘은 풀리지 않는다.

그래서 자료를 받았을 때의 물음은 하나로 모인다. 이 자료에 누가 들어왔고 누가 빠졌으며, 빠진 방식이 결과와 관계가 있는가. 이 물음에 답할 수 없으면 그 자료로 할 수 있는 말은 크게 줄어든다. 반대로 답할 수 있으면, 완벽하지 않은 자료로도 어느 방향으로 얼마나 조심해서 읽어야 하는지 알 수 있다. 그래서 4장의 결론은 좋은 자료를 구하라는 말이 아니다. 완벽한 자료는 거의 없고 있는 자료로 판단해야 하는 상황이 대부분이다. 필요한 것은 그 자료가 누구를 담고 있는지 아는 일이고, 그것만으로도 판단의 질은 크게 달라진다. 담긴 사람을 알면 결론에 붙일 조건도 정해진다.

5.1 배달 건수와 사고 건수

새들목 회의에서 오래 다룬 자료가 하나 있다. 골목의 배달 건수와 이륜차 사고 건수를 나란히 놓은 표였다. 두 숫자는 지난 몇 해 동안 나란히 늘었다.

회장 만수는 배달이 늘어 사고가 는 것이니 골목 안 배달 오토바이 진입을 제한하자고 했다. 배달 일을 하는 준영은 반대했다. 사고가 는 것은 배달 때문이 아니라 골목에 유동 인구가 늘고 노점이 늘어 길이 좁아진 탓이라는 것이었다.

두 주장 모두 같은 상관을 근거로 삼았다. 예린이 정리한 것은 셋째 값의 후보들이었다. 골목 유동 인구, 노점 수, 겨울철 노면 상태가 나왔고, 이 중 유동 인구는 배달 건수와 사고 건수 양쪽에 영향을 줄 만했다. 사람이 많으면 주문도 늘고 사고 위험도 커진다. 이 후보를 확인하기 전에는 어느 주장도 자료로 뒷받침되지 않았다. 두 사람이 같은 표를 보고 정반대 결론에 이른 것 자체가 흔한 일이다. 표가 두 결론 중 어느 것도 배제하지 못할 때 사람들은 자기가 이미 가진 이야기로 빈자리를 메운다. 만수에게는 오토바이가, 준영에게는 노점이 그 이야기였다.

5.1 배달 건수와 사고 건수

예린이 먼저 한 일은 나누어 보는 것이었다. 유동 인구가 비슷했던 기간끼리 묶어 배달 건수와 사고 건수를 다시 째지었다. 묶어서 보자 두 값의 관계는 눈에 띄게 약해졌다. 유동 인구가 상당 부분을 설명하고 있었던 것이다.

다음으로 확인한 것은 사고 건수 자료가 어떻게 만들어졌는지였다. 그 숫자는 상인회에 접수된 신고를 센 것이었다. 배달 오토바이가 얹힌 사고는 신고가 잘 되고, 보행자끼리 부딪힌 사고는 대개 그냥 넘어간다는 사실이 드러났다. 배달이 늘면 신고되는 사고의 비율 자체가 올라가는 구조였다.

두 확인을 마치자 표는 처음과 다르게 읽혔다. 배달이 사고를 늘렸다는 결론은 근거가 약해졌고, 대신 다음에 무엇을 모아야 하는지가 분명해졌다. 유동 인구를 같은 방식으로 재는 일과 신고에 기대지 않는 사고 기록을 만드는 일이다. 회의는 진입 제한 대신 이 두 가지를 결정했다. 결론을 미룬 셈이지만 미룬 값은 크지 않았다. 잘못 짚은 제한을 시행했다가 되돌리는 비용이 훨씬 컸을 것이기 때문이다.

5.2 야간 조명과 매출

2장에서 그림으로 보고 3장에서 구조를 따진 조명과 매출 사례를 이제 처음부터 끝까지 읽어 보자.

관측된 것은 조명을 오래 켜 가게일수록 매출이 높다는 상관이었다. 가능한 구조는 넷이다. 조명이 매출을 올렸거나, 매출이 좋아 늦게까지 열어 조명이 길어졌거나, 골목 같은 셋째 값이 둘을 함께 끌어올렸거나, 우연이었다.

넷을 하나씩 지워 나갔다. 골목별로 나누자 관계가 거의 사라졌으므로 셋째 값의 몫이 컸다. 가게 스무 곳으로 점을 늘려도 남는 약한 경향이 있었으므로 우연만은 아니었다. 남은 두 방향을 가르기 위해 예린이 본 것은 시간 순서였다. 매출이 오른 달과 조명 시간이 늘어난 달을 가게별로 견주자 대부분 매출이 먼저 움직였다. 다울의 가게도 그랬다. 방향은 대체로 매출에서 조명 쪽이었다. 대체로라고 적은 것은 예외가 있었기 때문이다. 스무 곳 중 세 곳은 조명이 먼저 늘고 매출이 따라 올랐다. 이 세 곳이 다른 무리와 무엇이 다른지는 아직 모르며, 회보에는 그 사실만 적혔다.

5.2 야간 조명과 매출


이 결론은 상인회의 계획을 바꿨다. 원래는 골목 전체의 조명 시간을 늘리는 데 예산을 쓸 참이었다.

방향이 매출에서 조명 쪽이라면 조명을 늘려도 매출은 따라오지 않는다. 오히려 전기료만 늘어 형편이 어려운 가게에 부담이 생긴다. 잘못 읽은 채로 집행했다면 효과 없는 지출을 하고, 몇 해 뒤에 조명을 늘렸는데도 매출이 안 올랐다는 결론만 남았을 것이다.

다만 예린은 회보에 조건을 함께 적었다. 시간 순서로 방향을 가른 것은 결정적인 증거가 아니며, 조명이 매출에 주는 영향이 아예 없다는 뜻도 아니라는 것이다. 확실히 하려면 조명을 늘릴 가게를 뽑기로 정해 비교집단을 만들어야 하는데, 참여할 가게가 모이지 않아 하지 못했다고 적었다. 할 수 있었던 것과 하지 못한 것을 함께 남긴 셈이다. 이렇게 적어 두면 다음 사람이 이어받기 쉬워진다. 몇 해 뒤 참여할 가게가 모이면 그때 뽑기로 나눠 확인하면 되고, 그때까지는 지금의 결론을 잠정으로 쓰면 된다. 결론을 잠정이라고 적는 일은 약해 보이지만 실제로는 다음 작업을 열어 두는 일이다.

같은 자료 두 가지 해석

점은 그대로인데 설명이 다르다




조명 시간 → / 매출 ↑

설명 하나

조명 → 매출

밝은 가게에 손님이 들어온다



조명 시간 → / 매출 ↑

설명 둘

매출 → 조명 · 골목 → 둘 다

잘되는 가게가 늦게까지 연다

두 설명을 가르려면 시간 순서, 무리 나누기,
또는 밖에서 만들어진 갈림이 필요하다

같은 점그림에 서로 다른 화살표를 엮을 수 있다.
엮은 화살표는 자료가 아니라 우리가 더한 것이다.

5.4 자연실험을 찾아내기

뽑기로 비교집단을 만들 수 없을 때 쓰는 방법이 하나 더 있다. 밖에서 일어난 일이 사람들을 우연에 가깝게 갈라놓은 상황을 찾아 쓰는 것이다. 이런 상황을 자연실험이라고 부른다.

새들목에 실제로 그런 일이 있었다. 골목 절반의 전선 공사가 두 달 동안 이어지면서 그 구간의 가로등이 꺼져 있었다. 어느 가게가 꺼진 구간에 있었는지는 가게의 사정과 무관하게 전선이 지나는 경로로 정해졌다. 의욕이 있는 주인이라고 켜진 구간에 있지 않았다.

이 상황은 뽑기와 비슷한 갈림을 만들어 준다. 공사 구간과 그렇지 않은 구간의 매출 변화를 견주면 조명의 효과를 어림할 수 있다. 새들목이 실제로 이 자료를 봤을 때 두 구간의 매출 변화에는 뚜렷한 차이가 없었고, 이것은 앞 절에서 시간 순서로 얻은 결론과 같은 방향이었다. 서로 다른 방법이 같은 답을 가리키면 그 답을 더 믿을 수 있다. 방법마다 약점이 다르기 때문이다. 두 방법이 같은 방향으로 틀리려면 두 약점이 우연히 같은 쪽을 향해야 하는데, 그럴 가능성은 하나만 쓸 때보다 낮다.

5.4 자연실험을 찾아내기

자연실험은 갈림이 우연에 가까울 때만 성립한다. 이 전제를 확인하지 않으면 그냥 두 무리를 견준 것과 다르지 않다.

새들목의 전선 공사에도 확인할 것이 있었다. 공사 구간이 정말 가게 사정과 무관하게 정해졌는가. 알아보니 공사는 오래된 전선부터 했고, 오래된 전선은 골목에서 먼저 자리 잡은 옛 구역에 몰려 있었다. 옛 구역의 가게들은 평균적으로 더 오래됐고 단골이 많았다.

그러면 두 구간은 조명 말고도 다른 점이 있는 셈이다. 예린은 이 점을 회보에 적고, 공사 전 여섯 달 동안 두 구간의 매출 흐름이 비슷했는지를 먼저 확인했다. 비슷했으므로 견줄 만하다고 판단했지만, 이 확인이 없었다면 결과를 그대로 쓰지 못했을 것이다. 자연실험을 쓸 때는 갈림이 어떻게 정해졌는지를 반드시 따져 봐야 한다. 따져 보는 방법은 대체로 하나다. 갈림이 생기기 전의 자료로 두 무리가 비슷했는지 확인하는 것이다. 이전에 나란히 움직이던 두 무리가 갈림 이후에 벌어졌다면 그 벌어짐을 갈림 탓으로 돌리기가 훨씬 수월해진다.

5.4 자연실험을 찾아내기

5장의 사례들을 되짚어 보면 같은 순서가 되풀이됐다.

먼저 자료가 어떻게 만들어졌는지 봤다. 사고 건수가 신고에 기대고 있다는 것을 그때 알았다. 다음으로 함께 움직이는지 확인하고, 그다음 그것이 인과일 수 있는 네 구조를 하나씩 지워 나갔다. 나누어 보기로 셋째 값을 확인하고, 시간 순서로 방향을 보고, 밖에서 만들어진 갈림이 있으면 그것을 썼다.

마지막으로 남은 불확실을 적었다. 어느 사례에서도 확실하다는 결론은 나오지 않았고, 대신 어느 방향으로 얼마나 조심해야 하는지가 남았다. 회보에는 그 조심할 지점이 결론과 함께 실렸다. 이 순서는 특별한 도구를 필요로 하지 않으며, 새들목처럼 작은 조사실에서도 그대로 쓸 수 있다. 필요한 것은 도구보다 순서를 지키는 규율이다. 결론이 먼저 떠오른 상태에서 자료를 보면 확인 단계 몇 개를 건너뛰기 쉬운데, 그 몇 개가 대개 결론을 뒤집을 수 있는 단계다. 회보 양식에 확인 항목을 인쇄해 둔 것도 그래서다. 종이에 적혀 있으면 건너뛴 자리가 눈에 띈다.

6.1 시점을 고르면 그림이 바뀐다

지금까지는 자료를 읽는 쪽의 실수를 다뤘다. 이 장에서는 자료를 보여 주는 쪽이 만드는 왜곡을 본다. 가장 흔한 것이 구간을 고르는 일이다.

새들목의 방문객 기록은 열 해치가 있다. 이 열 해에서 어느 구간을 잘라 보여 주느냐에 따라 전혀 다른 이야기가 만들어진다. 최근 세 해만 보이면 뚜렷한 감소로 보이고, 그 앞의 두 해를 포함하면 회복 뒤의 조정으로 보이며, 열 해를 다 퍼면 오르내림을 반복하는 완만한 상승으로 보인다.

세 그림 모두 거짓이 아니다. 같은 자료에서 잘라 낸 것이다. 그런데 보는 사람이 받는 인상은 정반대다. 그래서 구간이 정해진 표를 볼 때는 왜 그 구간인지를 물어야 한다. 자료가 그때부터 있어서인지, 그 구간이 이야기에 맞아서인지는 대개 자료를 만든 쪽만 안다. 물어봐서 답이 없으면 앞뒤를 더 붙여 다시 그려 보는 것이 안전하다. 앞뒤를 붙였을 때 이야기가 그대로면 그 구간 선택은 문제가 없었던 것이고, 달라지면 왜 달라지는지가 새로운 물음이 된다. 어느 쪽이든 확인해 볼 값어치는 있다.

6.1 시점을 고르면 그림이 바뀐다

가로축의 구간만 문제가 되는 것은 아니다. 세로축을 어디서 시작하느냐도 그림의 인상을 크게 바꾼다.

방문객이 열 해 동안 완만하게 오르내린 자료를 놓고, 세로축을 영에서 시작하면 거의 평평한 선이 된다. 그런데 세로축을 값들이 놓인 구간만 잘라 시작하면 같은 자료가 크게 출렁이는 선이 된다. 새들목 회보에도 두 방식이 다 등장한 적이 있고, 그해에 상권이 요동친다는 말과 안정적이라는 말이 함께 돌아왔다.

어느 쪽이 옳다고 정할 수는 없다. 작은 변화가 중요한 자료에서는 잘라 보는 편이 낫고, 규모를 보여 주려면 영에서 시작하는 편이 낫다. 요점은 고를 수 있다는 사실을 알고 보는 것이다. 그림을 볼 때 축의 시작점을 확인하는 습관을 들이면, 같은 자료를 다른 축으로 다시 그려 보는 일도 어렵지 않게 된다. 축을 고르는 일에는 정답이 없지만 정직한 방식은 있다. 잘라 그렸으면 잘랐다고 표시하고, 두 방식의 인상이 크게 다르면 둘 다 보여 주는 것이다. 새들목 회보가 요즘 그렇게 한다.

6.2 기저효과

변화율은 무엇에 견주었는지에 따라 크게 달라진다. 견주는 시점이 유난히 낮거나 높았다면 변화율은 실제 움직임보다 크게 또는 작게 나온다. 이것을 기저효과라고 부른다.

새들목에서 겪은 일이 있다. 골목 공사로 두 달 동안 사람이 거의 오지 않은 해가 있었고, 이듬해 같은 달의 방문객이 몇 배로 늘었다는 발표가 나왔다. 실제로는 공사 전 수준으로 돌아온 것뿐이었는데, 견주는 대상이 공사 기간이어서 변화율이 크게 나온 것이다.

반대 경우도 있다. 유난히 좋았던 해와 견주면 정상적인 해가 감소로 나타난다. 그래서 변화율만 적힌 발표를 볼 때는 견준 시점의 값 자체를 함께 봐야 한다. 여러 해 평균과 견주거나 원래 값을 그대로 늘어놓은 그림을 함께 두면 이 착시는 대부분 사라진다. 기저효과는 속이려는 의도 없이도 생긴다는 점이 성가시다. 변화율을 계산하는 사람은 규칙대로 계산했을 뿐이고, 견준 시점이 특이했다는 사실을 스스로도 모를 수 있다. 그래서 이것은 읽는 쪽에서 걸러야 하는 종류의 문제다.

6.2 기저효과

기저효과는 건주는 시점이 특이할 때만 생기는 것이 아니다. 원래 값이 작을 때도 같은 일이 벌어진다.


새들목 회보에 뒷길 카페의 배달 매출이 세 배로 늘었다는 문장이 실린 적이 있다. 실제 숫자를 보니 한 달에 두 건이던 것이 여섯 건이 된 것이었다. 같은 기간 시장 골목 식당은 백 건에서 백삼십 건으로 늘었다. 비율로는 앞쪽이 훨씬 크지만 건수로는 뒤쪽이 훨씬 많다.

어느 쪽을 보여 줄지는 무엇을 말하려느냐에 달려 있다. 새로운 시도가 자리 잡고 있다는 이야기라면 비율이 맞고, 골목 전체의 배달이 얼마나 늘었는지가 궁금하면 건수가 맞다. 문제는 둘 중 유리한 쪽만 보여 주는 것이다. 그래서 비율이 적힌 자리에는 원래 값도 함께 적는 것이 새들목 회보의 원칙이 됐다. 원칙을 세우고 나서 알게 된 것이 하나 있다. 원래 값을 함께 적자 몇몇 문장이 저절로 사라졌다. 두 건이 여섯 건이 됐다고 적으면 세 배라는 말을 굳이 붙일 필요가 없어졌기 때문이다. 표기 규칙 하나가 과장을 줄인 셈이다.

같은 자료 다른 구간

어디를 잘라 보여 주느냐에 따라

열 해치 전체 (열은 선)



최근 세 해



뚜렷한 감소

다섯 해



회복 뒤의 조정

열 해 전체



완만한 상승

세 그림 모두 같은 자료에서 잘라 낸 것이다.
구간이 정해진 표를 보면 왜 그 구간인지 물어야 한다.

6.4 지표가 목표가 되면

자료를 다루면서 마지막으로 조심할 것은, 재는 행위 자체가 재려던 것을 바꾼다는 사실이다.

새들목이 골목별 방문객 수를 회보에 실기 시작하자 몇 가지 일이 벌어졌다. 어떤 가게는 조사원이 서 있는 시간대에 맞춰 전단을 돌렸고, 어떤 골목은 행사를 조사 기간에 몰아 열었다. 방문객 수는 올라갔지만 그 골목의 사정이 실제로 나아졌는지는 다른 문제였다.

이런 현상은 숫자가 평가나 예산 배분에 쓰이기 시작할 때 특히 강해진다. 지표는 원래 실제 상태를 대신 보여 주는 그림자였는데, 그림자를 올리는 것이 목표가 되면 그림자와 실체가 갈라진다. 그래서 새들목은 지표를 하나만 쓰지 않고 성격이 다른 몇 개를 함께 보며, 어떤 지표가 유난히 좋아졌을 때는 그 지표를 올리는 다른 방법이 생기지 않았는지부터 확인한다. 이 현상은 지표를 만든 쪽의 잘못이 아니다. 사람들은 평가받는 기준에 맞춰 움직이게 마련이고 그것 자체는 자연스럽다. 문제는 그 움직임이 지표만 올리고 실체는 그대로일 때 생긴다. 그때부터 그 숫자는 상태가 아니라 노력의 방향을 보여 준다.

6.4 지표가 목표가 되면

지표가 왜곡된다고 해서 재는 일을 그만둘 수는 없다. 재지 않으면 나아졌는지 나빠졌는지 알 방법이 아예 없어진다. 대응은 그만두는 쪽이 아니라 곁들이는 쪽이다.

첫째, 성격이 다른 지표를 함께 둔다. 방문객 수와 함께 가게의 존속 기간을 보면, 방문객만 올리는 요령으로는 두 숫자를 동시에 좋게 만들기 어렵다. 둘째, 지표를 만드는 절차를 가끔 바꾼다. 조사 시간대를 미리 알리지 않으면 그 시간에 맞추는 일이 어려워진다.

셋째가 가장 중요하다. 숫자 옆에 그 숫자로 무엇을 말할 수 있고 무엇을 말할 수 없는지 적어 두는 것이다. 방문객 수는 골목에 사람이 얼마나 오는지를 보여 줄 뿐 가게가 잘되는지를 보여 주지는 않는다고 적어 두면, 그 숫자를 평가에 쓰려는 시도가 한 번은 걸러진다. 세 가지 모두 지표를 완전하게 만들지는 못한다. 완전한 지표는 없고, 무엇을 재든 재는 순간부터 그 숫자를 향한 움직임이 생긴다. 할 수 있는 일은 그 움직임을 예상하고 예상한 만큼 지표를 덜 믿는 것이다.

7.1 다섯 가지 물음

이 책이 지나온 것을 다섯 물음으로 묶을 수 있다. 낯선 표를 받았을 때 순서대로 던지면 된다.

첫째, 무엇을 센 숫자인가. 정의가 무엇이고 언제 바뀌었는가. 둘째, 어떻게 썼고 누가 빠졌는가. 답하지 않은 사람, 사라진 것, 스스로 고른 사람이 어디에 있는가. 셋째, 두 값이 함께 움직이는가. 그 경향이 점 몇 개에 기대고 있지는 않은가.

넷째, 함께 움직인다면 그 이유로 무엇이 가능한가. 셋째 값, 뒤집힌 방향, 우연을 하나씩 지워 봤는가. 다섯째, 이 그림은 왜 이 구간과 이 축으로 그려졌는가. 다른 구간으로 그리면 달라지는가.

다섯 물음 중 앞의 둘은 자료가 만들어지는 단계에 관한 것이고, 가운데 둘은 읽는 단계, 마지막 하나는 보여 주는 단계에 관한 것이다. 세 단계 중 어느 하나만 챙겨서는 부족하다. 다섯을 다 던지기 어려우면 첫째와 둘째만이라도 던지는 편이 낫다. 만들어진 방식이 잘못된 자료에서는 나머지 물음이 아무 의미가 없기 때문이다. 순서 자체가 중요도의 순서이기도 하다.

7.1 다섯 가지 물음

다섯 물음에 모두 답할 수 있는 자료는 드물다. 실제로는 답할 수 없는 물음이 한둘 남은 채로 판단해야 한다. 그때 할 수 있는 일이 있다.

먼저 말할 수 있는 범위를 줄인다. 방향을 가릴 수 없으면 함께 움직였다는 데까지만 적는다. 다음으로 어느 방향으로 틀릴 가능성이 큰지 적는다. 답하지 않은 쪽이 형편이 어려운 가게였다면 결과는 실제보다 좋게 나왔을 것이라고 적어 두는 식이다.

마지막으로 다음에 무엇을 모을지 정한다. 5.1의 사례에서 회의를 진입 제한 대신 자료 두 가지를 모으기로 한 것이 그렇다. 지금 답할 수 없는 물음이 다음번에는 답할 수 있는 물음이 되도록 만드는 것이, 자료를 다루는 일에서 한 번의 분석보다 오래 남는 성과다. 새들목 조사실이 열 해 동안 한 일의 대부분이 그것이었다. 정의를 적고, 절차를 남기고, 명단을 고정하고, 빠진 쪽을 따로 찾아가고, 겹쳐 재는 해를 만들었다. 어느 것도 한 번의 분석보다 화려하지 않지만, 지금 그 조사실이 답할 수 있는 물음의 범위를 만든 것은 이쪽이었다.

7.2 자료는 세상을 본 기록이다

1장에서 자료는 세상 자체가 아니라 어떤 절차로 세상을 본 기록이라고 적었다. 여러 장을 지나온 지금 그 문장은 처음보다 넓은 뜻을 갖는다.

4장의 편향들은 그 절차가 누구를 담고 누구를 뺐는지에 관한 것이었다. 3장의 교란과 역인과는 절차가 담지 못한 것들이 숫자 뒤에서 움직인 결과였다. 6장의 왜곡은 그 기록을 남에게 보여 주는 과정에서 한 번 더 걸러진 흔적이었다. 어느 단계에서도 세상이 그대로 옮겨진 적은 없다.

그렇다고 자료가 쓸모없다는 뜻은 아니다. 오히려 반대다. 기록이라는 것을 알고 보면 그 기록이 어디까지 말해 주는지 가늠할 수 있고, 가늠할 수 있으면 그 범위 안에서는 믿고 쓸 수 있다. 자료를 의심하는 일과 자료를 쓰는 일은 반대가 아니라 같은 작업의 앞뒤다. 의심을 어디서 멈출지도 함께 정해야 한다. 모든 자료에 흠이 있으므로 흠을 이유로 계속 미루면 아무 판단도 하지 못한다. 이 책이 원하는 멈춤의 기준은 하나다. 남은 흠이 결론의 방향을 바꿀 만한지 물어보고, 바꾸지 않을 만하면 조건을 적고 쓰는 것이다.

7.2 자료는 세상을 본 기록이다

이 책은 자료를 읽는 쪽에서 썼지만, 읽다 보면 만드는 쪽에 서게 되는 일도 생긴다. 그때 할 일은 앞의 다섯 물음을 뒤집어 놓는 것이다.

정의를 적어 두고 바뀐 해를 표시한다. 어떻게 모았는지와 무엇이 빠졌는지를 함께 남긴다. 상관을 보여 줄 때는 그것이 상관이라고 적고, 인과를 말하려면 무엇을 근거로 그렇게 말하는지 적는다. 구간과 축을 고른 이유를 적는다. 그리고 그 숫자로 말할 수 없는 것을 함께 적는다.

다섯 가지 모두 한 줄씩 더 적는 일이고 대단한 장치가 아니다. 그런데 이 한 줄들이 없으면 다음 사람은 그 자료로 아무 판단도 할 수 없거나, 더 나쁘게는 잘못된 판단을 자신 있게 하게 된다. 잘 만든 자료는 결론을 대신 내려 주지 않고 판단할 재료를 정직하게 넘겨준다. 넘겨받는 쪽을 생각하며 만드는 태도가 결국 자료의 질을 정한다. 지금 이 표를 몇 해 뒤에 처음 보는 사람이 읽는다고 생각하면 무엇을 적어야 하는지가 대체로 분명해진다. 새들목 조사실의 양식이 반 장짜리로 자리 잡은 것도 그 상상을 몇 번 되풀이한 결과였다.

7.3 다시 조사실로

다시 첫 장면으로 돌아가 보자. 예린의 숫자와 만수의 숫자가 두 배 가까이 같렸고, 둘 다 회보에 실릴 뻔했다.

이제 그 장면이 다르게 보인다. 두 숫자가 같린 것은 누가 틀려서가 아니라 서로 다른 정의로 서로 다른 절차를 밟았기 때문이다. 그리고 그 같림은 잘못이라기보다 알아차려야 할 사실이었다. 실제로 새들목 회보는 그해부터 두 숫자를 모두 실는다. 골목에 온 사람 수와 가게가 치른 응대 횟수라는 이름을 각각 붙이고, 어떻게 썼는지를 아래에 적어 둔다.

조사실은 올해도 자료를 모은다. 사고 기록을 신고에 기대지 않는 방식으로 바꾸는 일이 진행 중이고, 유동 인구를 같은 방식으로 재는 일도 시작했다. 무엇이 밝혀질지는 아직 모른다. 다만 무엇을 물어야 하는지는 알고 있고, 그것이 이 책이 남기고 싶은 전부다. 예린은 올해 회보의 첫 장에 다섯 물음을 인쇄해 두었다. 자료를 실는 사람과 읽는 사람이 같은 물음을 들고 있으면, 같린 숫자를 두고 다투는 대신 무엇이 같렸는지를 먼저 확인하게 된다.